Laporan Preprocessing dan Integrasi Data Kecelakaan Lalu Lintas Chicago, Periode 2018–2025

Ahmad Maulana Ibrahim
24/539655/TK/59853

1 Pemeriksaan Data dan Seleksi Atribut Awal

Data berasal dari tiga tabel terbuka City of Chicago: *Traffic Crashes–Crashes*, *Traffic Crashes–Vehicles*, dan *Traffic Crashes–People*. Crashes memuat satu baris untuk setiap kecelakaan, Vehicle satu baris untuk setiap unit yang terlibat, dan People satu baris untuk setiap orang. Ketiganya dapat dihubungkan dengan `crash_record_id`. Berkas yang dianalisis mencakup tahun 2018–2025.[1]

Table 1: Kondisi awal ketiga tabel. Persentase kosong dihitung dari semua sel pada masing-masing tabel.

Tabel	Baris	Kolom	Sel kosong	Kosong (%)
Crashes	877.921	49	9.001.923	20,93
Vehicle	1.792.372	71	93.017.957	73,09
People	1.927.657	29	22.063.385	39,47

Dataset dipilih karena memuat waktu, lokasi, kondisi jalan, jenis kendaraan, dan cedera orang. Ketiga sumber dapat menjawab pertanyaan lokasi, waktu, dan keterlibatan kendaraan, tetapi tingkat kekosongannya berbeda. Pemeriksaan awal menghitung baris, kolom, sel kosong, serta duplikat; tidak ditemukan baris atau ID ganda.

Sebelum cleaning, notebook mengeluarkan atribut yang kosong pada lebih dari 30% baris tabelnya. Aturan ini hanya berlaku untuk kolom; seluruh 4.597.950 baris dipertahankan. Kolom yang jarang terisi tidak dipakai dalam analisis umum agar tidak memerlukan terlalu banyak tebakan.

Table 2: Seleksi atribut awal berdasarkan batas lebih dari 30% nilai kosong.

Sumber	Kolom awal	Dikeluarkan	Kolom tersisa
Crashes	49	11	38
Vehicle	71	54	17
People	29	12	17
Total	149	77	72

Contoh atribut yang dikeluarkan adalah `work_zone_type` pada Crashes, atribut trailer pada Vehicle, dan `hospital` pada People. CSV mentah tetap disimpan untuk kajian yang membutuhkan atribut tersebut.

[1] Sumber: https://data.cityofchicago.org/d/85ca-t3if, https://data.cityofchicago.org/d/68nd-jvt3, dan https://data.cityofchicago.org/d/u6pd-qa9d.

2 Data Cleaning: Apa yang Diperbaiki dan Mengapa

Cleaning dilakukan tanpa menghapus baris sumber. Setiap perubahan dicatat agar nilai asli, nilai yang diperbaiki, dan nilai yang masih belum diketahui dapat dibedakan.

1. **Tulisan kosong dan format.** Spasi di awal/akhir dibuang; sel yang hanya berisi spasi diseragamkan menjadi kosong. Tanggal dan angka dibaca sesuai jenisnya. Langkah ini tidak mengisi nilai (0 sel); jumlah spasi yang dirapikan tidak dicatat terpisah dalam audit.
2. **Nilai tidak masuk akal.** Sebanyak 8 nilai `age` di luar 0–120 tahun dan 1.073 nilai `vehicle_year` yang tidak wajar dijadikan kosong: total 1.081 nilai ditandai, bukan diisi. Nilai asal disimpan pada `age_raw` dan `vehicle_year_raw`.
3. **Kategori yang kosong.** Pada kolom sumber, 3.314.281 sel diberi label status, bukan nilai faktual: 33.915 sel Crashes, 567.402 sel Vehicle, dan 2.712.964 sel People. Label `TIDAK_BERLAKU` digunakan ketika atribut tidak berlaku; `TIDAK_TERCATAT` ketika informasinya tidak ada. Contohnya, `report_type` diisi status 31.920 kali; enam atribut unit nonkendaraan, termasuk `make` dan `model`, masing-masing 41.431 kali diberi status tidak berlaku. Jumlah ini adalah sel, bukan baris unik.
4. **Pemeriksaan silang kolom sumber.** Kode memeriksa apakah koordinat dapat diperoleh dari teks `location` dan apakah total cedera dapat dijumlahkan dari empat komponen yang lengkap. Pada data ini kedua cara tersebut tidak menambah pengisian (0 sel). Nilai tanpa bukti yang cukup tetap kosong atau diberi label tidak tercatat.

Audit cleaning membedakan nilai sumber, label kategori, dan perkiraan. Tidak ada ID atau baris ganda yang dibuang. Perbandingan jumlah sel kosong disajikan setelah seluruh tahap pada Bagian 6.

3 Transformasi, Estimasi, dan Pemetaan Lokasi

Transformation mengubah bentuk atau menambah kolom agar data dapat dihitung dan dibandingkan. Kolom asli tetap tersedia jika sebuah perubahan bersifat perkiraan.

Table 3: Format awal kolom dan bentuk yang dipakai untuk analisis. Semua kolom CSV mula-mula dibaca sebagai teks.

Kolom asal dan format awal	Hasil dan format baru	Alasan
`crash_date`: teks tanggal ISO	Tanggal dan jam (`datetime`); kolom bulan, hari, dan jam sumber dibaca sebagai bilangan bulat.	Mengurutkan kejadian menurut waktu.
`age`: teks angka atau kosong	Usia bilangan bulat; `age_group` berupa kategori teks.	Membandingkan kelompok umur.
`age`, `vehicle_year`: teks angka atau kosong	Salinan `age_imputed` dan `vehicle_year_imputed` berupa angka; nilai kosong tertentu diisi median.	Memungkinkan analisis angka tanpa mengubah kolom asal.
`injuries_total`: teks angka; `most_severe_injury`: kategori teks	Kolom perkiraan total cedera berupa bilangan bulat dan tingkat keparahan berupa teks.	Melengkapi kasus yang jelas tercatat "tanpa cedera".
`latitude`, `longitude`: teks angka desimal; `location`: teks WKT	Koordinat berupa angka desimal; nomor area berupa bilangan bulat dan nama area berupa teks.	Mengelompokkan titik kecelakaan menurut wilayah.

Table 4: Contoh nilai sebelum dan sesudah transformasi dari hasil pemrosesan. Tanda "kosong" berarti nilai sumber tidak tersedia.

Kolom	Sebelum (CSV)	Sesudah (kolom analisis)
`crash_date`	`2018-01-01T00:00:00.000`	`2018-01-01 00:00:00` (tanggal–jam)
`age`	`39` (teks)	39 (angka); `age_group = 25-44`
`age` kosong	Pengemudi perempuan; usia kosong	`age_imputed = 36` (median kelompok)
`vehicle_year` kosong	Nissan Altima; tahun kosong	`vehicle_year_imputed = 2013`
Kolom cedera kosong	`crash_type`: tanpa cedera	`injuries_total_estimated = 0`; tingkat keparahan: tanpa cedera
Koordinat kosong	`latitude`, `longitude`: kosong	Estimasi 41,84613; −87, 69518; area South Lawndale

Usia yang kosong pada salinan analisis diisi dengan median (nilai tengah) orang yang mempunyai peran dan jenis kelamin sama; jika kelompoknya tidak cukup, median peran saja dipakai. Sebanyak 556.320 nilai pada `age_imputed` terisi. Salinan tahun kendaraan diisi dengan median merek–model yang memiliki sedikitnya 30 tahun kendaraan tercatat; 102.934 nilai terisi. Usia dan tahun kendaraan pada kolom asal tetap kosong ketika nilainya tidak diketahui.

Sesudah cleaning, 1.159 dari 7.068 kecelakaan tanpa koordinat mendapat perkiraan titik dari pencocokan alamat Census.[2] Pada 1.096 dari 1.987 kecelakaan tanpa `injuries_total`, total cedera diperkirakan nol dan tingkat keparahan diperkirakan "tanpa cedera" karena `crash_type` menyatakan tidak ada cedera. Perkiraan berada di kolom baru dengan penanda, sehingga nilai sumber tidak tertimpa. Sebanyak 5.909 lokasi, 891 total cedera, dan 898 tingkat keparahan masih belum diketahui. Titik dengan koordinat yang dapat dipakai kemudian dicocokkan dengan batas 77 *community area*[3]: 870.436 kecelakaan dari koordinat asli dan 1.150 dari koordinat estimasi masuk ke suatu area. Sebanyak 6.335 kecelakaan tetap memiliki status area belum diketahui; tidak dipaksa masuk ke area terdekat.

4 Integrasi: Tiga Sumber Menjadi Enam Tabel

Crashes dihubungkan dengan Vehicle dan People melalui `crash_record_id`. Untuk menghubungkan satu orang ke satu unit, digunakan `vehicle_id` bersama ID kecelakaan yang sama. Pola `person_id` dipakai hanya jika hubungannya unik dan dapat diperiksa. Jumlah orang dan kendaraan dihitung terlebih dahulu per kecelakaan, baru ditambahkan ke Crashes. Dengan cara ini, dua orang dalam dua kendaraan tidak berubah menjadi empat kecelakaan.

[2] https://geocoding.geo.census.gov/geocoder/Geocoding_Services_API.html.
[3] Batas wilayah: https://data.cityofchicago.org/d/igwz-8jzy.

Table 5: Enam tabel hasil integrasi dan ringkasan. “Satu baris” menentukan apa yang boleh dihitung.

Tabel dan arti satu baris	Baris	Kolom	Isi utama
`integrated_crashes`: satu kecelakaan	877.921	67	Tanggal, kondisi, cedera, jumlah orang dan kendaraan, area, asal koordinat.
`integrated_vehicles`: satu unit	1.792.372	38	Jenis, merek, model, kondisi kecelakaan, dan orang dalam unit yang terhubung.
`integrated_people`: satu orang	1.927.657	45	Usia, cedera, lokasi, kondisi kecelakaan, dan konteks kendaraan jika tautannya pasti.
`area_impact_summary`: satu area	77	13	Kecelakaan, orang, korban, kendaraan, dan kejadian berat per area.
`hourly_risk_summary`: hari–jam	168	9	Kecelakaan, korban, kendaraan, dan kejadian berat untuk 7 hari × 24 jam.
`vehicle_severity_summary`: jenis–keparahan	122	7	Unit, kecelakaan unik yang melibatkan jenis itu, dan cedera penghuninya.

Table 6: Lima community area dengan kecelakaan terbanyak dari `area_impact_summary`; kolom utama.

Area	Kecelakaan	Korban	Kendaraan	Kec. berat
Austin	41.495	10.695	84.238	868
Near West Side	40.539	8.005	79.359	692
Near North Side	38.912	6.333	74.604	549
Loop	28.342	5.218	54.849	487
West Town	25.581	5.096	50.309	457

Table 7: Lima kombinasi hari–jam dengan kecelakaan terbanyak dari `hourly_risk_summary`; kode hari mengikuti sumber.

Hari	Jam	Kecelakaan	Korban	Kec. berat
6	15	11.630	2.144	147
6	16	11.437	2.153	169
6	17	10.902	1.953	160
5	16	10.560	2.037	144
5	15	10.494	2.040	130

Table 8: Lima kombinasi jenis kendaraan–keparahan dengan unit terbanyak dari `vehicle_severity_summary`; kolom utama.

Jenis kendaraan	Keparahan kecelakaan	Unit	Kecelakaan unik
PASSENGER	NO INDICATION OF INJURY	918.720	604.539
SPORT UTILITY VEHICLE (SUV)	NO INDICATION OF INJURY	217.685	181.301
UNKNOWN/NA	NO INDICATION OF INJURY	142.211	132.796
PASSENGER	NONINCAPACITATING INJURY	93.398	59.576
VAN/MINI-VAN	NO INDICATION OF INJURY	66.617	63.805

Tabel area dan hari–jam tetap memuat kategori dengan nol kejadian.

Ringkasan Vehicle dapat dihubungkan dengan seluruh 877.921 kecelakaan, sedangkan People dapat dihubungkan dengan 875.934 kecelakaan. Ada 1.901 perbedaan antara angka `num_units` dan jumlah unit yang terhubung, serta 1.895 perbedaan antara ringkasan cedera People dan Crashes. Perbedaan tersebut ditandai, bukan ditimpa. Kolom kondisi kecelakaan yang muncul lagi pada Vehicle dan People tidak boleh dijumlahkan langsung; jumlah kecelakaan harus dihitung dari ID kecelakaan yang unik. Satu kecelakaan juga dapat melibatkan beberapa jenis kendaraan, sehingga jumlah kecelakaan antarjenis tidak boleh dijumlahkan sebagai total kota.

5 Pemeriksaan Redundansi dan Reduksi Akhir

Sesudah integrasi, notebook membandingkan kolom numerik pada satu baris per kecelakaan. Korelasi Pearson mengukur kemiripan pola; kovarians menunjukkan arah dan skala hubungan; persentase nilai sama memeriksa apakah dua hitungan hampir identik. Pemeriksaan ini dilakukan pada `integrated_crashes` agar kolom konteks yang berulang pada Vehicle dan People tidak membuat hubungan semu.

Table 9: Pasangan hitungan yang mirip pada tabel kecelakaan terintegrasi.

Pasangan kolom	Korelasi	Nilai sama (%)
`people_count`–`people_record_count`	1,000	100,00
`injuries_total`–`injured_people_count`	0,995	99,83
`injuries_fatal`–`fatal_people_count`	0,990	99,998
`num_units`–`vehicle_unit_count`	0,975	99,78

Kemiripan tinggi tidak berarti kedua kolom selalu dapat dipertukarkan; selisih jumlah unit dan cedera tetap dicatat dalam audit. Kode notebook lalu menyiapkan `analysis_crashes_reduced` dengan 15 dari 67 kolom tabel kecelakaan terintegrasi. Sebanyak 52 kolom tidak disalin (77,6% lebih sedikit), sedangkan 877.921 baris tetap ada.

Table 10: Isi tabel kecelakaan terpilih dan alasan pengurangan.

Dipertahankan	Tidak disalin ke tabel analisis
ID, tanggal, batas kecepatan, cuaca, penerangan, permukaan jalan, jenis tabrakan, jumlah kendaraan bermotor dan orang, total cedera dan kematian, serta nomor, nama, dan status area.	Salinan hitungan orang/cedera yang hampir sama, bulan dan jam yang dapat diturunkan dari tanggal, serta alamat dan koordinat rinci ketika analisis cukup memakai community area.

6 Perbandingan Sebelum–Sesudah dan Pemeriksaan Hasil

Jumlah kolom tidak selalu turun pada setiap tahap. Seleksi awal mengurangi kolom sumber, lalu cleaning dan integrasi menambah kolom penanda, perkiraan, serta hasil hubungan. Karena itu, tabel berikut membandingkan *kolom sumber yang sama* sebelum dan sesudah cleaning.

Table 11: Sel kosong pada kolom sumber yang dipertahankan. Jumlah baris setiap sumber tidak berubah.

Sumber	Sebelum	Sesudah	Berkurang (%)
Crashes	71.679	37.764	47,3
Vehicle	975.108	408.779	58,1
People	3.311.532	598.576	81,9

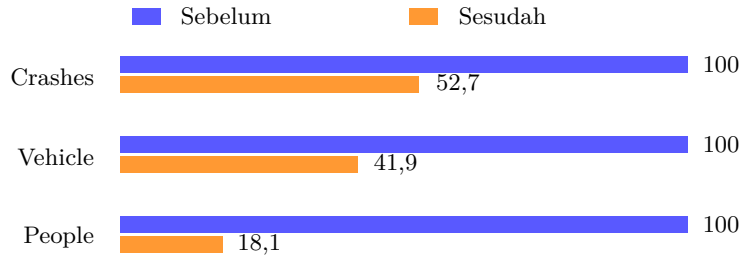


Figure 1: Sel kosong pada kolom yang dipertahankan. Nilai sebelum dibuat 100 untuk tiap tabel; batang sesudah menunjukkan sisa persentasenya.

Penurunan sel kosong sebagian besar berasal dari label `TIDAK_TERCATAT` dan `TIDAK_BERLAKU`; label tersebut tidak menambah fakta yang sebelumnya hilang. Jumlah kolom berubah dari 49 menjadi 38 setelah seleksi awal dan 67 setelah integrasi pada Crashes; untuk Vehicle 71 menjadi 17 lalu 38; untuk People 29 menjadi 17 lalu 45. Kode reduksi akhir memilih 15 kolom dari tabel Crashes terintegrasi.

Pemeriksaan akhir menunjukkan tabel rinci tetap berisi 877.921 kecelakaan, 1.792.372 unit, dan 1.927.657 orang. Sebanyak 871.586 kecelakaan dapat dipetakan ke 77 area; ditambah 6.335 yang belum terpetakan, jumlahnya tepat 877.921. Jumlah kecelakaan pada 168 kombinasi hari–jam juga 877.921. Koordinat dan cedera yang diperkirakan mempunyai penanda tersendiri.

7 Analisis, Temuan Utama, dan Ringkasan

Jumlah kecelakaan turun dari 117.764 pada 2019 menjadi 92.096 pada 2020 (sekitar 21,8%), lalu kembali ke kisaran 108–112 ribu per tahun. Proporsi kecelakaan dengan cedera tercatat naik dari 13,97% pada 2018 menjadi 16,44% pada 2025. Ini adalah pola pada data yang dilaporkan, bukan bukti perubahan risiko perjalanan.

Table 12: Tiga community area dengan jumlah kecelakaan terpetakan tertinggi.

Area	Kecelakaan	Korban	Meninggal
Austin	41.495	10.695	54
Near West Side	40.539	8.005	34
Near North Side	38.912	6.333	21

Austin memiliki 25,77 korban per 100 kecelakaan, sedangkan Near North Side 16,28. Lima area dengan kecelakaan terbanyak menampung 20,06% kecelakaan yang dapat dipetakan. Perbandingan ini belum memperhitungkan jumlah penduduk, perjalanan, atau kendaraan yang melewati tiap area.

Jumat pukul 15.00 mencatat kecelakaan terbanyak pada tabel hari–jam (11.630), sedangkan Kamis pukul 17.00 mencatat korban terbanyak (2.164). Kendaraan jenis `PASSENGER` tercatat pada 1.087.111 unit yang terlibat, diikuti SUV sebanyak 254.447 unit. Pada jenis tabrakan, 17,20% kecelakaan dengan pejalan kaki tergolong berat, dibanding 0,96% pada tabrakan belakang. Angka keterlibatan dan persentase ini tidak menunjukkan penyebab ataupun risiko per perjalanan karena data jumlah perjalanan tidak tersedia.

Ringkasan

Seleksi awal mengeluarkan 77 dari 149 kolom sumber tanpa menghapus baris. Integrasi menghasilkan tiga tabel rinci dan tiga tabel ringkasan. Dari 877.921 kecelakaan, 871.586 dapat dipetakan ke *community area*; 6.335 sisanya tetap tercatat tanpa area. Kode reduksi memilih 15 dari 67 kolom tabel kecelakaan terintegrasi untuk analisis umum. Perkiraan tidak menimpa nilai sumber: 5.909 lokasi dan 891 total

cedera masih belum diketahui. Perbandingan jumlah kecelakaan antarwilayah belum menunjukkan risiko per perjalanan karena jumlah perjalanan tidak tersedia.