UNIVERSITAS
GADJAH MADA



Individual Project: Preprocessing Data Kecelakaan Lalu Lintas Chicago

Ahmad Maulana Ibrahim
24/539655/TK/59853

LOCALLY ROOTED,
GLOBALLY RESPECTED

ugm.ac.id

Dataset yang Digunakan

Dataset utama:

1. City of Chicago Traffic Crashes – Crashes (2018-2025)
2. City of Chicago Traffic Crashes – Vehicles (2018-2025)
3. City of Chicago Traffic Crashes – People (2018-2025)

Dataset tambahan:

1. City of Chicago Community Area Map

Dataset yang Digunakan

Traffic Crashes – Crashes

- Berisi data kecelakaan Kota Chicago dalam rentang waktu 2018-2025
- Terdiri dari 49 kolom
- Berisi 877.921 baris data tanpa duplikasi
- Persentase data kosong 20.93%

Traffic Crashes – Vehicles

- Berisi data kendaraan yang terlibat dalam kecelakaan Kota Chicago (2018-2025)
- Terdiri dari 71 kolom
- Berisi 1.792.372 baris data tanpa duplikasi
- Persentase data kosong 73.09%

Traffic Crashes – People

- Berisi data orang yang terlibat dalam kecelakaan Kota Chicago (2018-2025)
- Terdiri dari 29 kolom
- Berisi 1.921.657 baris data tanpa duplikasi
- Persentase data kosong 39.47%

Ketiga tabel terhubung melalui kolom crash_record_id

Dataset tambahan: City of Chicago Community Area Map

Temuan Awal

- **77** kolom memiliki nilai kosong lebih dari 30%: 11 kolom Crashes, 54 Vehicles, dan 12 People.
- **7.068** kecelakaan tidak memiliki pasangan koordinat yang lengkap.
- **1.987** baris Crashes tidak memiliki nilai injuries_total.
- Ditemukan **8** usia di luar rentang 0–120 tahun dan **1.073** data Vehicle dengan tahun yang tidak valid.
- Koordinat (latitude, longitude) memerlukan konteks agar dapat memberikan informasi.
- Satu kecelakaan dapat terkait dengan banyak unit dan orang, sehingga integrasi berisiko menggandakan jumlah data.

Cleaning dan Transformasi

Masalah atau kolom	Tindakan	Hasil
Sel kosong dan spasi	Normalisasi menjadi nilai kosong	Format lebih konsisten
Usia dan tahun kendaraan tidak wajar	Jadikan kosong pada kolom bersih	8 usia dan 1.073 tahun ditandai
Usia/tahun kendaraan tidak diketahui	Imputasi median pada kolom baru	`age_imputed`: 556.320; `vehicle_year_imputed`: 102.934
Total cedera kosong, berisi teks “NO INJURY” atau ”DRIVE AWAY”	Diubah ke dalam integer bernilai 0	1.096 nilai `injuries_total_estimated = 0`
Sebagian kolom memiliki banyak missing value	Hapus atribut dengan >30% kosong	77 kolom dihapus
Tanggal dan waktu dalam satu kolom	Dipisah ke dalam dua kolom dengan format yang konsisten	Dua kolom terpisah: date dan time

Cleaning dan Transformasi – Perbandingan

Jumlah kolom per tahap

Dataset	Mentah	Dihapus (>30% kosong)	Bersih	Transformasi
Crashes	49	11	44	67
Vehicles	71	54	21	36
People	29	12	24	43

Perubahan jumlah data kosong

Dataset	Sebelum	Sesudah cleaning	Penurunan
Crashes	71.679	37.764	47,3%
Vehicles	975.108	408.779	58,1%
People	3.311.532	598.576	81,9%

Missing Data dan Transformation

- Kategori kosong diberi label TIDAK_TERCATAT atau TIDAK_BERLAKU sesuai maknanya.
- Salinan usia dan tahun kendaraan diisi dengan median kelompok, tanpa mengganti nilai sumber.
- **1.159 lokasi** diperkirakan melalui pencocokan alamat; **1.096 total cedera** diperkirakan nol berdasarkan tipe kecelakaan.

Estimasi dan Pemetaan Community Area

Status koordinat	Jumlah kecelakaan
Dipetakan dari koordinat asli	870.436
Dipetakan dari koordinat estimasi	1.150
Koordinat masih kosong	5.909
Di luar batas area	371
Koordinat tidak valid	55
Total	**877.921**

- **871.586 koordinat kecelakaan** berhasil dipetakan ke 77 community area.
- Geocoder menghasilkan 1.159 estimasi alamat; 1.150 masuk ke salah satu area.
- Dari 1.987 total cedera yang kosong, 1.096 diestimasi nol; **891 tetap belum diketahui**.

Integrasi

Hubungan	Kunci atau langkah
People ↔ Vehicles	`vehicle_id` dan `crash_record_id` yang sama
People/Vehicles → Crashes	Ringkas jumlah orang dan unit per `crash_record_id` sebelum digabung
Koordinat → Community area	Cocokkan titik dengan poligon 77 area

- satu baris pada setiap tabel integrasi tetap mewakili satu kecelakaan, satu unit, atau satu orang. Konteks kecelakaan yang berulang tidak dijumlahkan kembali.

Integrasi – Enam Dataset Akhir

Dataset akhir	Grain	Baris × kolom	Isi dan kegunaan
integrated_crashes	Kecelakaan	877.921 × 67	Kondisi, lokasi, jumlah orang/unit, dan cedera per kecelakaan
integrated_vehicles	Unit terlibat	1.792.372 × 36	Tipe dan karakteristik unit serta konteks kecelakaan
integrated_people	Orang	1.927.657 × 43	Peran, usia, cedera, dan konteks kecelakaan/unit
area_impact_summary	Community area	77 × 13	Kecelakaan, korban, dan kendaraan berdasarkan community area
hourly_risk_summary	Hari × jam	168 × 9	Kecelakaan dan korban menurut hari serta jam
vehicle_severity_summary	Tipe kendaraan × keparahan	122 × 7	Keterlibatan unit dan cedera penghuni menurut keparahan

Redundansi dan Reduksi Atribut

Pasangan atribut	Korelasi Pearson	Nilai sama
`people_count – people_record_count`	1,000	100,00%
`injuries_total – injured_people_count`	0,995	99,83%
`injuries_fatal – fatal_people_count`	0,990	99,998%

- Tiga pasangan memiliki korelasi absolut ≥0,98.
- Tabel analisis kecelakaan dipilih dari **67 menjadi 15 kolom**; **877.921 baris tetap dipertahankan**.
- Tanggal dipakai untuk menurunkan fitur waktu; lokasi dapat diringkas ke community area. Tabel integrasi lengkap tetap tersedia untuk penelusuran.

Sampel 3 Tabel Integrasi

area_impact_summary — satu baris per community area

Community area	Kecelakaan	Korban	Kendaraan	Kecelakaan berat
Austin	41.495	10.695	84.238	868
Near West Side	40.539	8.005	79.359	692
Near North Side	38.912	6.333	74.604	549
Loop	28.342	5.218	54.849	487
West Town	25.581	5.096	50.309	457

Sampel 3 Tabel Integrasi

hourly_risk_summary — satu baris per hari dan jam

Hari	Jam	Kecelakaan	Korban	Kecelakaan berat
Jumat	15	11.630	2.144	147
Jumat	16	11.437	2.153	169
Jumat	17	10.902	1.953	160
Kamis	16	10.560	2.037	144
Kamis	15	10.494	2.040	130

Sampel 3 Tabel Integrasi

vehicle_severity_summary — satu baris per jenis kendaraan dan tingkat keparahan

Jenis kendaraan	Keparahan	Unit	Kecelakaan unik
PASSENGER	NO INDICATION OF INJURY	918.720	604.539
SPORT UTILITY VEHICLE (SUV)	NO INDICATION OF INJURY	217.685	181.301
UNKNOWN/NA	NO INDICATION OF INJURY	142.211	132.796
PASSENGER	NONINCAPACITATING INJURY	93.398	59.576
VAN/MINI-VAN	NO INDICATION OF INJURY	66.617	63.805

Temuan Analisis dan Kesimpulan

Temuan	Angka
Kecelakaan turun dari 2019 ke 2020	117.764 → 92.096 (−21,8%)
Area dengan kecelakaan terpetakan terbanyak	Austin: 41.495 kecelakaan; 10.695 korban
Waktu dengan kecelakaan terbanyak	Jumat pukul 15.00: 11.630
Waktu dengan korban terbanyak	Kamis pukul 17.00: 2.164
Kecelakaan dengan cedera saat hujan vs cerah	18,62% vs 15,55%

UNIVERSITAS
GADJAH MADA

QnA

